

1. Why do we need an activation function in a neural network? What happens if we don't use one?

Activation function-এর প্রধান কাজ হলো neural network-এ **non-linearity introduce** করা। যদি **activation function** ব্যবহার না করি? তাহলে অনেকগুলো layer থাকলেও পুরো neural network শেষ পর্যন্ত একটি **linear function** হিসেবেই কাজ করবে। অর্থাৎ complex/non-linear problem, যেমন **XOR**, properly solve করতে পারবে না।

2. Explain why sigmoid is called a “squashing function”.

Sigmoid function:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

এর output সবসময়:

$$0 < \sigma(z) < 1$$

অর্থাৎ input z যত বড় positive বা negative হোক, sigmoid সেটাকে 0 থেকে 1-এর মধ্যে squeeze/squash করে।

That's why it is called the squashing function.

3. Why is ReLU more popular than Sigmoid in deep neural networks?

ReLU:

$$ReLU(x) = \max(0, x)$$

ReLU-এর সবচেয়ে বড় সুবিধা হলো **positive region-এ gradient vanish করে না।**

Sigmoid-এর ক্ষেত্রে large positive/negative input-এ gradient খুব ছোট হয়ে যায়।

Sigmoid derivative:

$$\sigma'(x) = \sigma(x)(1 - \sigma(x))$$

এর maximum value মাত্র:

$$0.25$$

তাই অনেক layer-এর মধ্যে gradient বারবার ছোট হতে হতে **vanishing gradient** তৈরি করতে পারে।

ReLU-এর positive region-এ:

$$ReLU'(x) = 1$$

তাই deep network-এ training সাধারণত সহজ হয়।

4. What problem does ReLU solve compared to Sigmoid?

মূলত vanishing gradient problem কমাতে সাহায্য করে।

Sigmoid-এর derivative:

$$0 < \sigma'(x) \leq 0.25$$

তাই backpropagation-এর সময় gradient অনেক ছোট হয়ে যেতে পারে।

ReLU:

$$ReLU(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases}$$

এবং $x > 0$ হলে:

$$ReLU'(x) = 1$$

তাই positive region-এ gradient ছোট হয়ে যায় না।

মনে রাখো:

Sigmoid → Vanishing Gradient

ReLU → helps reduce Vanishing Gradient

5. When should we use Softmax instead of Sigmoid?

For multiclass classification, we use softmax.

6. Why is Binary Cross Entropy preferred over MSE for classification?

BCE classification-এর জন্য বেশি suitable কারণ এটি predicted probability এবং actual class-এর mismatch ভালোভাবে measure করে।

BCE:

$$L = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

Classification-এ ভুল prediction-এর জন্য BCE বড় penalty দেয়।